

SDN マルチコントローラ環境における負荷分散を目的とした BiLSTM による負荷予測

石橋研究室 BGB23010 趙 麓暉

1. はじめに

ソフトウェア定義ネットワーク (SDN) は、制御プレーンとデータプレーンを分離し、ネットワークの転送ルールをコントローラが管理することで、従来のネットワーク管理を変革する技術である。特に OpenFlow 1.2 以降、複数コントローラのサポートが可能となり、SDN のコントローラクラスタ技術が注目されている。しかし、静的なスイッチとコントローラの対応関係により負荷分散が困難になり、ネットワーク性能の低下を招くという課題がある。OpenFlow v1.3 ではフェイルオーバーや負荷分散が可能だが、スイッチ移行の具体的なメカニズムは規定されていない。そのため、従来のランダムなスイッチ移行手法では、移行コストの増加や負荷分散効率の低下が課題となっていた。

本研究では、BiLSTM を用いた負荷予測手法を導入し、将来的な負荷を予測することで、より効率的なスイッチ移行を実現することを目的とする。実験では、BiLSTM と LSTM を比較し、トラフィックパターンを分析した。

2. 提案手法

本研究では、BiLSTM を用いた SDN マルチコントローラ環境の負荷予測手法を提案する。

具体的には、Packet-In メッセージの到達率を主要な負荷指標とし、過去のトラフィックデータを学習することで、将来的なコントローラ負荷を高精度に予測する。これにより、過負荷状態が発生する前に適切なスイッチ移行を行うことが可能となり、全体的な負荷バランスの改善を図る。本提案手法では、文献[3]において提案されている、LSTM を用いた予測方式のモデルを BiLSTM に変更して実験を行い、LSTM との比較を実施した。その結果、BiLSTM モデルはより高い予測精度が得られることを確認した。

2.1 SDN コントローラ負荷の定義

負荷分散のための指標として、一定時刻の区間にコントローラがスイッチから受信する packet-in 数をコントローラの負荷と定義する[1]。

$$Load_{C_i T_n} = \sum_{S_k \in Q_{C_i}} f_{S_k} T_n \quad (1)$$

式 1 の意味は次の通りである。ある時間区間 T_n において、スイッチ S_k からのリクエストメッセージの数を記録し、これを $f_{S_k} T_n$ と表記する。これは、スイッチ S_k が T_n にもたら負荷を示し、その総計を $Load_{C_i T_n}$ と定義する。

2.2 トラフィックマトリックス (TM)

トラフィックマトリックス (TM) は、コンピュータネットワーク内の全ての送信元-宛先 (OD) ノードの間で流れるトラフィック量を特定の時刻において表すものである。SDN において広く用いられる OpenFlow プロトコルでは、各ノードの流量情報を容易に収集でき、さらに他のノードへのトラフィック量も抽出可能である。そのため、基盤となるネットワーク構造に依存することなく、高精度なトラフィックマトリックス (TM) を構築することができる[3]。具体的に、 M が最大管理スイッチ数にして、 W がスライディングウィンドウのサイズを表すとトラフィックコレクションマトリックス TCM は $M \times W$ の行列式(2)として定義される。

$$TCM = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1W} \\ X_{21} & X_{22} & \dots & X_{2W} \\ \vdots & \vdots & \ddots & \vdots \\ X_{M1} & X_{M2} & \dots & X_{MW} \end{bmatrix} \quad (2)$$

2.3 トラフィックマトリックス (Traffic Matrix) の予測

直近の固定数のタイムスロットを学習し、現在のトラフィックベクトル X_t を予測する手法である[2]。 M はコントローラが管理するスイッチの最大数を表し、 W はスライディングウィンドウのサイズを示す[4]。




図 1 時間経過に伴うトラフィックマトリックス予測

トラフィック収集マトリックスにおいて、 X_{ij} はコントローラドメイン内の i 番目のスイッチがコントローラに送信するトラフィック量を表す。具体的には、タイムスロット $[j, j + \Delta t]$ においてスイッチがコントローラに送信した packet-in メッセージの数に相当する[4]。

2.3 予測に用いられる代表的な深層学習モデル

(1) LSTM(長短期記憶)

勾配消失問題を解決するために設計された再帰型ニューラルネットワーク (RNN) の一種であり、過去の長期間の依存関係を考慮して時系列データを学習できる。順方向の情報のみに基づいて将来のデータを予測するため、文脈の前後関係を完全には考慮できないという課題がある。

(2) BiLSTM (双方向 LSTM)

LSTM を拡張し、順方向と逆方向の両方からデータを学習することで、より精度の高い時系列予測を実現する。過去と未来の情報を同時に利用できるため、コン

テキストの完全な理解が可能になり,特に自然言語処理やトラフィック予測に優れている。

3. 実験と評価

実験: BiLSTM モデルの訓練と予測

これによって,BiLSTM モデルを訓練し,損失値 (loss) の変化を記録した.エポック数は最大 200,バッチサイズは 32 に設定し,学習が早期停止 (early_stopping) の条件を満たした場合は途中で停止する.ウィンドウサイズ look_back = (1,2,3,4,...,10)テストした中で最適な値はウィンドウサイズは 6,epoch=103 で,最小検証損失は $3.82e^{-5}$ であった訓練損失と検証損失の推移を可視化した結果を図 2 に示す.

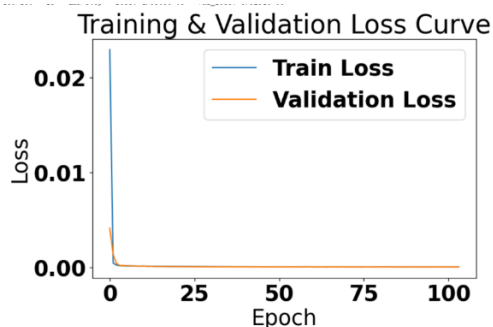


図 2 訓練損失と検証損失の推移

BiLSTM と LSTM がデータに適切に適合していることが図 3 に示されている. BiLSTM モデルは,過去と未来の情報を同時に活用することで,特にデータセットの終盤において,LSTM モデルよりも予測精度が高いことが示されています.これは,BiLSTM が双方向の情報を持つため,将来の変化を予測時に考慮できるからです.その結果,LSTM よりも実測値に近い予測が可能となる.特に,急激な負荷の低下が発生する場面では,LSTM は直前のデータ (まだ負荷が高い状態) に影響され,減少スピードが遅くなる傾向があります.一方,BiLSTM はすでに減少のパターンを把握し,先回りして予測を最適化できるため,より滑らかな予測曲線を描ける.また,LSTM は長期記憶が弱いため,データの終盤になるほど誤差が増大する傾向がありますが,BiLSTM は双方向に情報を流すため,終盤の負荷パターンにも過去データが影響しやすく,予測精度の向上に寄与する.これらの特性により,BiLSTM は時系列データの予測において,LSTM よりも優れた性能を発揮することが多いとされている.




図 3 データフィッティング

BiLSTM と LSTM 評価指標の比較

表 1 結果比較

モデル	MSE(10^{-5})	RMSE(10^{-3})	MAE(10^{-3})	R^2	look_back
LSTM	26.9	16.4	14.9	0.89	8
BiLSTM	3.71	6.09	3.1	0.98	8
LSTM	6.10	7.81	4.61	0.97	9
BiLSTM	6.54	8.08	5.30	0.97	9

look_back が 8 のときは BiLSTM が最良,9 のときは LSTM のほうがわずかに良いという結果が得られた。

4. 関連研究

Junbi Xiaora らの研究[5]では,BiLSTM+Attention モデルを用いて packet-in メッセージの数を予測し,コントローラの過負荷を予測した際にスイッチの移行を早期決定する手法を実装し,他の手法との比較を行った.この手法により,スイッチの移行コストと負荷分散の分散が低減されることが確認された。

この方式では,スイッチ移行の最適化を行うことで,従来の手法 (TSSM,DDM) と比較して負荷分散の効率を 27.6%向上させ,移行コストを 16% (TSSM 比),8% (DDM 比) 削減できることを実験的に示した.また,LPSM では,スイッチ移行の対象となるコントローラを選択するために,ネットワークトラフィック,CPU 利用率,メモリ使用率,ネットワーク帯域幅などの複数の要素を考慮したアルゴリズムを導入した. 本研究では論文[5]に基づいて BiLSTM を用いた負荷予測の試みを行った。

5. おわりに

本論文では,OpenFlow に基づく通信特徴抽出を用いて,Packet-In 到達率をシミュレートしたデータセットで BiLSTM モデルの訓練を行い,その結果を従来のモデルと比較した.また,トラフィックマトリックスによるトラフィック予測手法の改良について考察を行った。

参考文献

- [1] Cui, J., Lu, Q., Zhong, H., Tian, M., & Liu, L. (2018). A load-balancing mechanism for distributed SDN control plane using response time. IEEE transactions on network and service management, 15(4), 1197-1206.
- [2] Azzouni, A., & Pujolle, G. (2018, April). NeuTM: A neural network-based framework for traffic matrix prediction in SDN. In NOMS 2018-2018 IEEE/IFIP Network Operations and Management Symposium (pp. 1-5). IEEE.
- [3] Le, D. H., Tran, H. A., Souihi, S., & Mellouk, A. (2021, June). An ai-based traffic matrix prediction solution for software-defined network. In ICC 2021-IEEE International Conference on Communications (pp. 1-6). IEEE.
- [4] Zhong, H., Xu, J., Cui, J., Sun, X., Gu, C., & Liu, L. (2022). Prediction-based dual-weight switch migration scheme for SDN load balancing. Computer Networks, 205, 108749.
- [5] Xiao, J., Pan, X., Liu, J., Wang, J., Zhang, P., & Abualigah, L. (2024). Load balancing strategy for SDN multi-controller clusters based on load prediction. The Journal of Supercomputing, 80(4), 5136-5162.